

Universidade Federal de Pernambuco
Centro de Ciências Exatas e da Natureza
Departamento de Estatística

TÓPICOS ESPECIAIS EM ESTATÍSTICA COMPUTACIONAL

Título: Predição de Níveis de Renda usando Redes Neurais: Análise Comparativa de Técnicas de Regularização

María José García Montes

Data: 06 de diciembre de 2025

Abstract

Este estudo investiga a eficácia de redes neurais totalmente conectadas na predição de níveis de renda com base em características demográficas e laborais. Utilizando o Adult Census Dataset (32.561 observações), foram implementadas e comparadas duas arquiteturas: uma rede neural simples e outra incorporando técnicas de dropout para regularização. Os resultados demonstram que a arquitetura com dropout alcançou desempenho superior em termos de generalização, reduzindo significativamente o overfitting em 11.14 e obtendo 85.71 de acurácia nos dados de teste, em comparação com 81.97 do modelo simples.

Palavras-chave: Redes Neurais, Dropout, Modelo Simple

Introdução

A predição de níveis de renda baseada em características individuais constitui um problema relevante tanto no âmbito acadêmico quanto aplicado. Modelos precisos podem auxiliar em políticas públicas, segmentação de mercado e estudos socioeconômicos. Tradicionalmente, técnicas estatísticas como regressão logística têm sido empregadas para esta finalidade, porém redes neurais artificiais emergem como alternativas promissoras devido à sua capacidade de capturar relações não-lineares complexas.

O desafio central no emprego de redes neurais reside na tendência ao overfitting, especialmente em conjuntos de dados com dimensionalidade elevada e relações complexas entre variáveis. A técnica de dropout, introduzida por Srivastava et al. (2014), surge como uma solução elegante e eficaz para este problema, promovendo a aprendizagem de representações mais robustas através da desativação aleatória de neurônios durante o treinamento.

Este trabalho tem como objetivo principal comparar o desempenho de redes neurais totalmente conectadas com e sem dropout na predição de níveis de renda utilizando o Adult Census Dataset. Especificamente, busca-se: (i) implementar ambas as arquiteturas; (ii) avaliar métricas de desempenho comparativas

Fundamentação Teórica

Redes Neurais Artificiais

As redes neurais artificiais consistem em unidades de processamento interconectadas (neurônios) organizadas em camadas sequenciais. Para um problema de classificação binária, como a predição de renda, a função de ativação na camada de saída utiliza tipicamente a função sigmoide:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

onde z apresenta a combinação linear das entradas da camada anterior Segundo (Hastie, Tibshirani, and Friedman 2009)

Redes Neurais Totalmente Conectadas

Uma rede neural totalmente conectada (Multilayer Perceptron – MLP) é composta por camadas densas, nas quais cada neurônio se conecta a todos os neurônios da camada seguinte. Matematicamente, uma camada oculta pode ser representada como:

$$\mathbf{H} = \varphi(\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)})$$

e a saída como:

$$\mathbf{O} = \varphi(\mathbf{H}\mathbf{W}^{(2)} + \mathbf{b}^{(2)})$$

onde $\varphi(\cdot)$ é uma função de ativação não linear, $\mathbf{H}$ representa o vetor de entradas, $\mathbf{W}^{(2)}$ os pesos da primeira camada e $\mathbf{b}^{(2)}$ o vetor de vieses. A composição de múltiplas camadas permite aproximar funções complexas e modelar interações não lineares entre variáveis, segundo (Ferreira 2025c)

Overfitting

O overfitting ocorre quando um modelo aprende ruídos e padrões específicos do conjunto de treinamento, degradando seu desempenho em dados não vistos. Em redes profundas, o elevado número de parâmetros aumenta esse risco, especialmente quando as variáveis são numerosas ou apresentam colinearidade e ruído, segundo (Ferreira 2025a)

Dropout como Técnica de Regularização

O Dropout é uma técnica que “desativa” aleatoriamente neurônios durante o treinamento com uma probabilidade p . Esse processo força a rede a aprender representações mais robustas e distribuídas, reduzindo a coadaptação entre neurônios. Conceitualmente, o Dropout pode ser interpretado como um ensemble implícito de múltiplas sub-redes, o que melhora a capacidade de generalização. Durante a fase de inferência, todas as neurônios são ativados, segundo (Srivastava et al. 2014)

Matriz de Confusão e Métricas de Avaliação

Para problemas de classificação binária como a predição de níveis de renda, a **matriz de confusão** é uma ferramenta importante para avaliar o desempenho do modelo Ferreira (2025b).

Aplicação

Utilizou-se o Adult Census Dataset, disponível no repositório da UCI Machine Learning, composto por 32.561 observações e 15 variáveis, das quais 6 são variáveis numéricas, 8 variáveis categóricas e a variável resposta é income, categorizada em dois níveis: $\leq 50K$ e $> 50K$.

Análise Exploratória

Como se observa na Figure 1, existe um desequilíbrio significativo na distribuição dos níveis de renda, em que 24.720 observações pertencem ao nível de renda inferior ($\leq 50K$), enquanto apenas 7.841 se encontram no nível superior ($> 50K$).




Figure 1: Distribuição dos Níveis de Renda.

Fonte: *Elaboração própria*

Além disso, a composição demográfica revela uma distribuição desigual por gênero, com predominância masculina de 66.9 (21.790 homens) em comparação com 33.1 de representação feminina (10.771 mulheres).

Também se verificou que os indivíduos com maiores rendas apresentaram características distintivas: idade média de 44.2 anos e nível educacional médio de 11.6 anos de educação formal. Essas estatísticas refletem tendências consistentes com a literatura socioeconômica, na qual a experiência laboral acumulada e a educação formal estão positivamente associadas a níveis mais elevados de renda.

Para lidar com o desbalanceamento de classes encontrado, foram criadas duas redes neurais com a mesma estrutura de 4 camadas (256 – 128 – 64 – 32 neurônios), mas em uma delas foram adicionadas camadas de dropout progressivo (50). Ambas foram treinadas com o otimizador Adam durante 100 épocas, utilizando o conjunto de treinamento (80 dos dados) para o aprendizado e reservando os 20 restantes para validação, o que permitiu comparar especificamente se o dropout auxilia o modelo a generalizar melhor em dados.

Avaliação do Desempenho Preditivo

A análise comparativa revelou diferenças significativas no desempenho entre ambas as arquiteturas. Como se apresenta na Table 1, o modelo com dropout demonstrou superioridade consistente em todas as métricas avaliadas.

A melhoria mais notável foi observada na precisão (+9.17, indicando que o modelo regularizado é significativamente mais confiável ao prever a classe minoritária ($> 50K$). O F1-Score, que equilibra precisão e recall, apresentou uma melhoria de 6.0, refletindo um equilíbrio geral mais adequado na classificação.

Table 1: Comparación de métricas entre arquitecturas

Métrica	Red Simple	Red com Dropout	Melhora
Accuracy	81.97%	85.71%	+3.74%
Precisão	63.47%	72.64%	+9.17%
Recall	59.18%	65.18%	+6.0%
F1-Score	61.25%	68.71%	+7.46%
AUC-ROC	0.8691	0.9063	+0.0372
Loss	1.1812	0.3440	-0.8372

Fonte: *Elaboração própria*

Na Table 2, observam-se padrões distintivos na capacidade de generalização de ambas as arquiteturas. A rede neural simples apresenta um comportamento de sobreajuste: embora tenha alcançado 95.35 de precisão nos dados de treinamento, seu desempenho reduziu-se para 81.97 na validação, refletindo uma diferença de 13.38 entre os dois conjuntos. Essa discrepância sugere que o modelo capturou ruídos e padrões específicos do conjunto de treinamento, comprometendo sua aplicabilidade a dados novos.

Em contraste, a rede com dropout demonstrou um perfil de aprendizado substancialmente mais robusto. Como se observa na Tabela Table 2, embora tenha apresentado uma precisão de treinamento mais moderada (87.94, manteve um desempenho consistentemente elevado na validação (85.71, reduzindo a diferença de sobreajuste para apenas 2.24. Essa melhoria de 11.14 pontos percentuais em generalização, combinada com um ganho de 3.74 pontos em precisão preditiva real, valida a efetividade do dropout como mecanismo de regularização.

A estratégia evidencia que, em problemas de classificação com dados complexos, priorizar a capacidade de generalização, mesmo à custa de um desempenho ligeiramente inferior no treinamento, resulta em modelos mais confiáveis e com maior aplicabilidade em cenários reais.

Table 2: Análisis de overfitting entre arquitecturas

Métrica	Red Simple	Red com Dropout	Melhora
Accuracy Entrenamiento	95.35%	87.94%	-7.41%
Accuracy Validación	81.97%	85.71%	+3.74%
Overfitting	13.38%	2.24%	-11.14%

Fonte: *Elaboração própria*

Na Figura 2a, o modelo simples evidencia sobreajuste, refletido em uma diferença considerável entre as curvas de accuracy de treinamento e validação. Enquanto o treinamento alcança aproximadamente 95, a validação se estabiliza em torno de 81.9, o que indica baixa capacidade de generalização. Em contraste, o modelo que incorpora a técnica de Dropout demonstra curvas mais estáveis e próximas entre si, alcançando um accuracy de validação final de 85.7. Esses resultados confirmam a efetividade da regularização por Dropout na melhoria do desempenho preditivo da rede neural.

Este resultado se confirma na Figura 2b, onde o modelo simples apresenta aumento da perda em validação, enquanto a perda em treinamento continua diminuindo, evidenciando a ocorrência de sobreajuste. Em contraste, o modelo com aplicação da técnica de Dropout mantém ambas as curvas descendentes e próximas entre si, indicando um processo de treinamento mais estável e com maior capacidade de generalização.




Figura 2a: Evolução de la Accuracy

Figura 2b: Evolução de la Loss

Fonte: Elaboração própria

A Figure 2 apresenta as curvas ROC correspondentes a ambos os modelos. Observa-se que o modelo com aplicação da técnica de Dropout exhibe uma curva que se mantém consistentemente acima da curva do modelo simples, indicando uma maior taxa de verdadeiros positivos para um mesmo nível de falsos positivos.

Além disso, a curva do modelo com Dropout aproxima-se de forma mais consistente do lado superior esquerdo do gráfico, região que representa uma classificação ideal. O valor da AUC confirma essa superioridade, com 0.906 em comparação a 0.869, evidenciando uma maior capacidade de discriminação entre as classes.




Figure 2: Avaliação da Accuracy

Fonte: Elaboração própria

Na tabela Table 4, observa-se que o modelo simples identifica corretamente 4.411 instâncias da classe majoritária ($\leq 50K$), o que representa uma taxa de acerto de 89,20. No entanto, para a classe minoritária ($> 50K$), o modelo acerta apenas 928 dos 1.568 casos reais, resultando em uma taxa de acerto de 59,18.

Table 4: Matriz de Confusão - Modelo Simple

Valor Real Valor Predito	$\leq 50K$	$> 50K$	Total	Tasa de Acerto
$\leq 50K$	4.411	534	4,945	89.20%
$> 50K$	640	928	1,568	59.18%
Total	5,051	1,462	6,513	

Valor Real				Tasa de
Valor Predito	$\leq 50K$	$> 50K$	Total	Acierto
Precisión por Clase	87.33%	63.48%		Accuracy Global: 81.97%

Fonte: *Elaboração própria*

Na tabela Table 5, o modelo com Dropout melhora em ambas as classes: +3,01 na classe majoritária e +5,99 na minoritária.

Table 5: Matriz de Confusão - Modelo com Dropout

Valor Real				Tasa de
Valor Predito	$\leq 50K$	$> 50K$	Total	Acierto
$\leq 50K$	4,560	385	4,945	92.21%
$> 50K$	546	1,022	1,568	65.17%
Total	5,106	1,407	6,513	
Precisión por Clase	89.31%	72.64%		Accuracy Global: 85.71%

Fonte: *Elaboração própria*

Conclusão

Os resultados obtidos ao longo deste estudo evidenciam que o modelo simples apresenta limitações significativas, refletidas na discrepância entre as curvas de treinamento e validação, no aumento da perda durante a validação e no desempenho inferior em métricas como accuracy e AUC. Esses achados confirmam a ocorrência de limitações, comprometendo a capacidade preditiva do modelo quando aplicado a novos dados.

Em contraste, o modelo com Dropout demonstrou maior estabilidade ao longo do processo de treinamento, apresentando curvas de desempenho mais próximas entre si e métricas superiores. O aumento consistente do accuracy de validação, a redução da perda e a superioridade tanto da curva ROC quanto do valor de AUC (0.906 em comparação a 0.869) confirmam a efetividade de dropout na melhoria da capacidade de discriminação entre classes.

Assim, conclui-se que a aplicação de Dropout, é importante para o desempenho de redes neurais na tarefa de predição de níveis de renda, garantindo maior robustez e confiabilidade dos resultados.

Referências

- Ferreira, Jodavid. 2025a. “Dropout.”
- . 2025b. “Matriz de Confusão e Métricas de Avaliação.” <https://jodavid.github.io/computationalstatisticstoppers/>.
- . 2025c. “Redes Neurais Totalmente Conectadas.”
- Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009. *The Elements of Statistical Learning*. Springer New York. <https://doi.org/10.1007/978-0-387-84858-7>.
- Srivastava, Nitish, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. 2014. “Dropout: A Simple Way to Prevent Neural Networks from Overfitting.” *Journal of Machine Learning Research* 15: 1929–58.